Разведочный анализ данных (EDA)

Разведочный анализ это первый, “ознакомительный” этап работы с данными. Задача - посмотреть, что вообще есть в данных, найти скрытые закономерности, странности и противоречия, проверить первые предположения и сформулировать гипотезы. Для этого используются визуализация, описательная статистика, группировки, рейтинги и другие простые инструменты - до того, как строить прогнозные или причинно-следственные модели.

Описание исследования

- **Название:** Проведение разведочного анализа данных о состоянии физической культуры в России
- **Авторы:** Параскевопуло О.Р., Гельмиярова В.Н., Козлова О.Ю., Кузнецова Е.Ю., Немировская-Дутчак О.Э.
- **Год:** 2024
- **DOI:** 10.55186/2413046X_2023_9_1_3
- **Ссылка:** CyberLeninka

Обоснование выбора

В статье прямо заявлено использование методов, характерных для EDA:

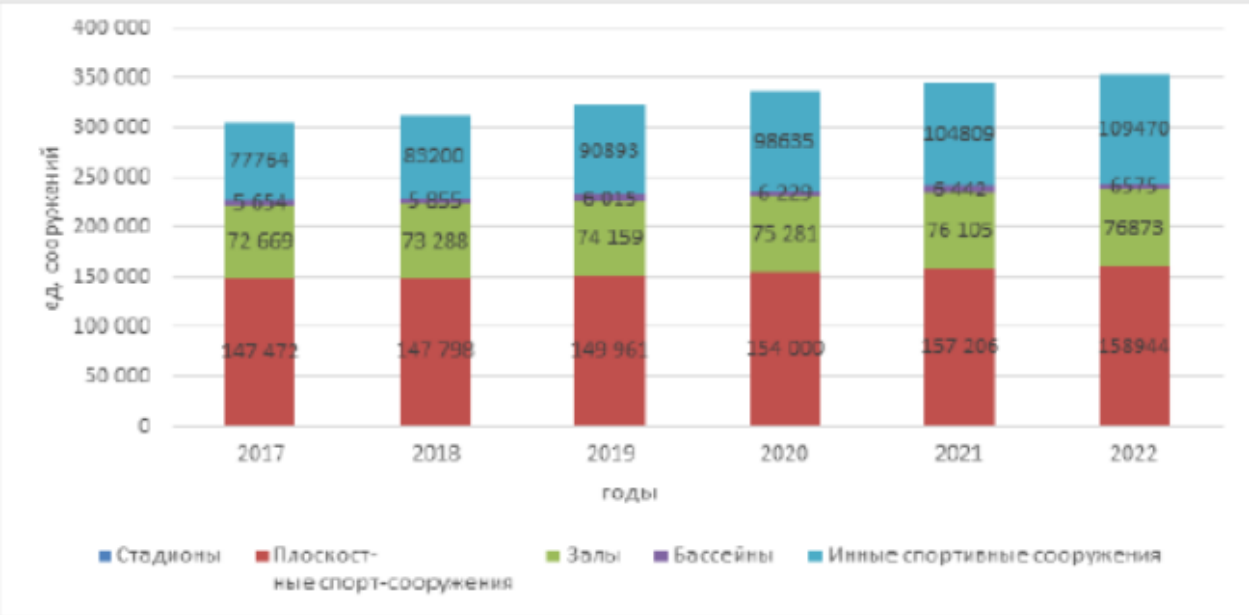
- классификация и систематизация данных;
- нормировка статистических показателей;
- рейтингование регионов;
- табличное и графическое представление данных.

Авторы отмечают:

> «Статистические исследования позволяют получить объективную информацию о том, как часто и каким образом люди занимаются физической активностью, какие виды спорта являются наиболее популярными, как изменяется уровень подготовленности населения».

Исследователи не строят сразу строгую причинно-следственную модель - вместо этого проводится первичное “углубление” в данные: анализируются разнородные показатели по регионам, выявляются противоречия между подходами, фиксируются тренды. Что отлично ложится на цель разведочного анализа данных - сформулировать гипотезы для дальнейшего моделирования

Одна из таблиц статьи



Механистический анализ данных

Механистический анализ нужен не для того, чтобы просто найти статистическую корреляцию. Его задача - понять и математически описать внутренний механизм процесса, который порождает данные: физический, биохимический, экономический и т.д. У параметров таких моделей есть конкретный предметный смысл.

Описание исследования

- **Название:** Развитие методов прогнозирования структуры потока на вертикальных участках нефтяных скважин
- **Авторы:** Михайлов В.Г., Волков М.Г.
- **Год:** 2024
- **DOI:** 10.24412/2076-6785-2024-6-100-105
- **Ссылка:** CyberLeninka

Обоснование выбора

Авторы противопоставляют свои методы чисто эмпирическим подходам, отмечая, что последние «не обладают требуемой точностью» вне узкого диапазона условий. В работе используется механистическое моделирование: новые критерии прогнозирования структуры газожидкостного потока разработаны на основе решения фундаментального уравнения сохранения количества движения

Упрощённая форма уравнения баланса импульса для вертикального участка скважины имеет вид:

$$\frac{dP}{dz} = -\rho_m g \sin\theta - \frac{f_m \rho_m v_m^2}{2D} - \frac{d}{dz}\left(\alpha \rho_g v_g^2 + (1-\alpha)\rho_l v_l^2\right)$$

где:

- P — давление,
- ρ_m — плотность смеси,
- g — ускорение свободного падения,
- f_m — коэффициент трения смеси,
- v_m — скорость смеси,
- D — диаметр трубы,
- α — объёмное содержание газовой фазы.

Этапы механистического анализа в исследовании:

1. Формулировка физической модели процесса (двухфазный поток);
2. Запись уравнений сохранения (массы, импульса);
3. Анализ условий структурного перехода (пробковый - пузырьковый режим);
4. Получение критериев перехода без эмпирических коэффициентов;
5. Верификация модели на промысловых данных.

Сравнительный анализ подходов

Критерий	Разведочный анализ (EDA)	Механистический анализ
Основная цель	Выявление закономерностей, формулировка гипотез	Понимание внутреннего механизма процесса
Тип модели	Описательная, визуальная	Физико-математическая
Интерпретируемость	Средняя	Высокая (параметры имеют физический смысл)
Применимость	Широкая, без знания физики процесса	Требует знания предметной области
Пример из работы	Рейтингование регионов по спорту	Прогноз режима течения в скважине

Заключение

В ходе работы были рассмотрены два вида анализа данных:

Разведочный анализ - первичное изучение данных; визуализация и описательная статистика; формулирование гипотез.

Механистический анализ - построение физически обоснованных моделей; использование фундаментальных законов; объяснение причинно-следственных связей.

Оба подхода взаимодополняют друг друга в реальном исследовании: EDA помогает понять структуру данных и сформулировать гипотезы, а механистический анализ - раскрыть механизм изучаемого явления

Список использованных источников

1. Параскевопуло О.Р. и др. Проведение разведочного анализа данных о состоянии физической культуры в России // Наука и спорт: современное состояние. 2024. DOI: 10.55186/2413046X_2023_9_1_3

2. Михайлов В.Г., Волков М.Г. Развитие методов прогнозирования структуры потока на вертикальных участках нефтяных скважин // Инженерно-строительный журнал. 2024. DOI: 10.24412/2076-6785-2024-6-100-105
3. Репозиторий проекта на GitHub: https://github.com/MiiroSun/RStudio